

Traditional 与 Learning-based 事件表示更新对比报告

2026-05-08

实验范围与读数原则。 本报告更新了 N-MNIST learning-based 结果，并保留 N-Caltech101 与 MVSEC 的既有对比。为了避免混淆，N-MNIST 被分成两类结果：第一类是完整官方测试集或仓库记录的 full-result，对应传统方法和仓库已有 EvRepSL；第二类是本次新跑的 7 个 learning-based sanity-scale 结果，设置为 CPU、10 epoch、train/test limit 2048/512、batch size 32、learning rate 0.0001。这组 sanity 结果可以证明代码路径、表示构建和分类器训练是通的，但不应被当作完整 official-split benchmark 结论。

N-MNIST Full Result Saturation. 在完整 N-MNIST 结果中，最佳 traditional 方法是 Voxel Grid，准确率为 99.08%；仓库已有 learning-based EvRepSL 为 98.81%。二者差距只有 0.27 个百分点，Time Surface、Event Frame 和 Timestamp Image 也均处在 98% 以上。因此，N-MNIST 更适合作为接口和训练流程验证任务，而不是强区分表示能力的核心任务。Binary Event Image 为 95.06%，是完整 N-MNIST 中唯一明显掉队的方法，说明只保留二值触发信息会损失一部分时序和强度线索。

N-MNIST Sanity Runs Are Not Ranking Evidence. 本次新增的 7 个 learning-based 本地结果在 2048/512 小规模 N-MNIST 设置上全部达到 100.00% test accuracy，这说明这些方法的本地 adapter、表示张量和 ResNet18 classifier 路径均能正常工作。但由于测试样本只有 512 个，且 N-MNIST 本身接近饱和，这组结果不能用于声称某个 learning-based 方法显著优于另一个方法。若只看训练早期，EvRepSL 的 epoch-1 train accuracy 最高，为 97.17%；最终 train loss 最低的也是 EvRepSL，为 0.0015。这更像是收敛速度差异，而不是泛化能力差异。

N-Caltech101 Separates Representation Capacity. 与 N-MNIST 不同，N-Caltech101 对表示能力的区分更明显。当前最佳 learning-based 方法是 EST adaptation，准确率为 70.44%；最佳 traditional 方法是 Timestamp Image，准确率为 52.93%。二者相差 17.51 个百分点。这个差距说明，在类别更多、形状更复杂的事件分类任务上，学习型表示或端到端学习 pipeline 更容易组织跨时间的判别信息；traditional baseline 仍然重要，但更适合作为非学习表示下界。

MVSEC Shows A Different Pattern. MVSEC optical flow 使用 outdoor_day1/2 训练、indoor_flying1/2/3 测试，并共享 EVFlowNet-like decoder，因此比分类任务更接近统一协议比较。在这个设置下，最佳方法是 Timestamp Image，AEE 为 2.7916，outlier rate 为 36.61%；最佳 learning-based 方法是 EST，AEE 为 2.8654。这说明 timestamp-preserving traditional representation 在光流估计中具有很强竞争力。需要谨慎表述的是，这并不等价于 traditional 方法在原文完整 setting 中全面超过 learning-based 方法，而是在本仓库统一 decoder 和统一 early-stopping protocol 下取得了更低 AEE。

汇报建议。 晚上汇报可以采用三句话主线。第一，N-MNIST 基本接近饱和，完整结果中 Voxel Grid 与 EvRepSL 仅差 0.27 个百分点，新跑的 7 个 learning-based sanity 结果全部达到 100%，因此它主要证明 pipeline 可运行。第二，N-Caltech101 才更能拉开差距，EST adaptation 比最佳 traditional Timestamp Image 高 17.51 个百分点，说明复杂分类任务上 learning-based 表示优势更明显。第三，MVSEC 呈现不同结论：统一协议下 Timestamp Image 的 AEE 低于当前 learning-based 最优 EST，说明传统事件表示并不是弱 baseline，尤其保留时间戳结构的表示值得在 survey 中重点讨论。




Figure 1: N-MNIST 完整结果准确率对比。橙色为 traditional baseline，蓝色为仓库已有 learning-based full result。




Figure 2: 新跑 N-MNIST learning-based sanity-scale 结果。所有方法在 2048/512 小规模划分上达到 100% test accuracy，因此图中展示 epoch-1 train accuracy 和最终 train loss，用于观察收敛速度而非最终排名。




Figure 3: N-Caltech101 分类准确率对比。蓝色为 learning-based 方法，橙色为 traditional baseline。




Figure 4: MVSEC optical flow 统一协议下的 AEE 对比。AEE 越低越好，横轴采用局部放大以展示 2.79–3.02 区间内的差异。